Entrega final de proyecto

Ariel Eduardo Bedoya Marín.
Identificación: 71275506
Mayo 2023.

Universidad de Antioquia.
Ingeniería de Sistemas.
Introducción a la inteligencia artificial para las ciencias e ingenierías.

Resultados alcanzados

Con los análisis iniciales del dataset, se llega a entender que este posee información muy básica para realizar predicciones a cerca de qué géneros de videojuegos podrían ser potencialmente deseables para que las comercializadoras y/o editoras quieran iniciar un desarrollo. Sin embargo, se hace interesante la idea de abordar experimentos que permitan buscar relaciones o patrones de los géneros de videojuegos más vendidos en determinados años, para cuáles plataformas fueron lanzados y cuáles has sido sus empresas publicadoras.

De momento, uno de los mayores obstáculos para manipular el dataset es, irónicamente, su simpleza, debido a que contiene pocas columnas, es decir, hay pocas variables con las cuales buscar correlaciones que lleguen a generar un proyecto complejo. Lo anterior no quiere decir que no sea posible implementar modelos predictivos interesantes y complejos que permitan ver algún tipo de resultado sea positivo o no y así llegar a conclusiones y análisis.

Ya dicho lo anterior, se puede decir que, al momento de hacer este informe, se ha realizado una exploración de los datos, incluyendo procesos para llamar el dataset desde kaggle (por medio de su API). Dentro de esta exploración se ha notado que hay años de publicación faltantes para algunos videojuegos y así mismo faltan algunos nombres de sus publicadores.

```
Rank            0
Platform        0
Year          271
Genre           0
Publisher      58
NA_Sales        0
EU_Sales        0
JP_Sales        0
Other_Sales     0
Global_Sales    0
dtype: int64

Year         271
Publisher     58
dtype: int64
```

Se ha realizado un reemplazo del índice, el cual estaba numerado, por el nombre del videojuego. Esto debido a que el nombre es único y no proveerá mucha información dentro de las predicciones. Se verificó el tipo de datos, dentro de estos se observó que el año era de tipo ‘Float64’ y por lo tanto se convirtió a un tipo entero (‘Int64’). Se verificaron los datos faltantes y también se contrastó a través de gráficas, las relaciones que podrían o no, tener las variables del conjunto de datos.

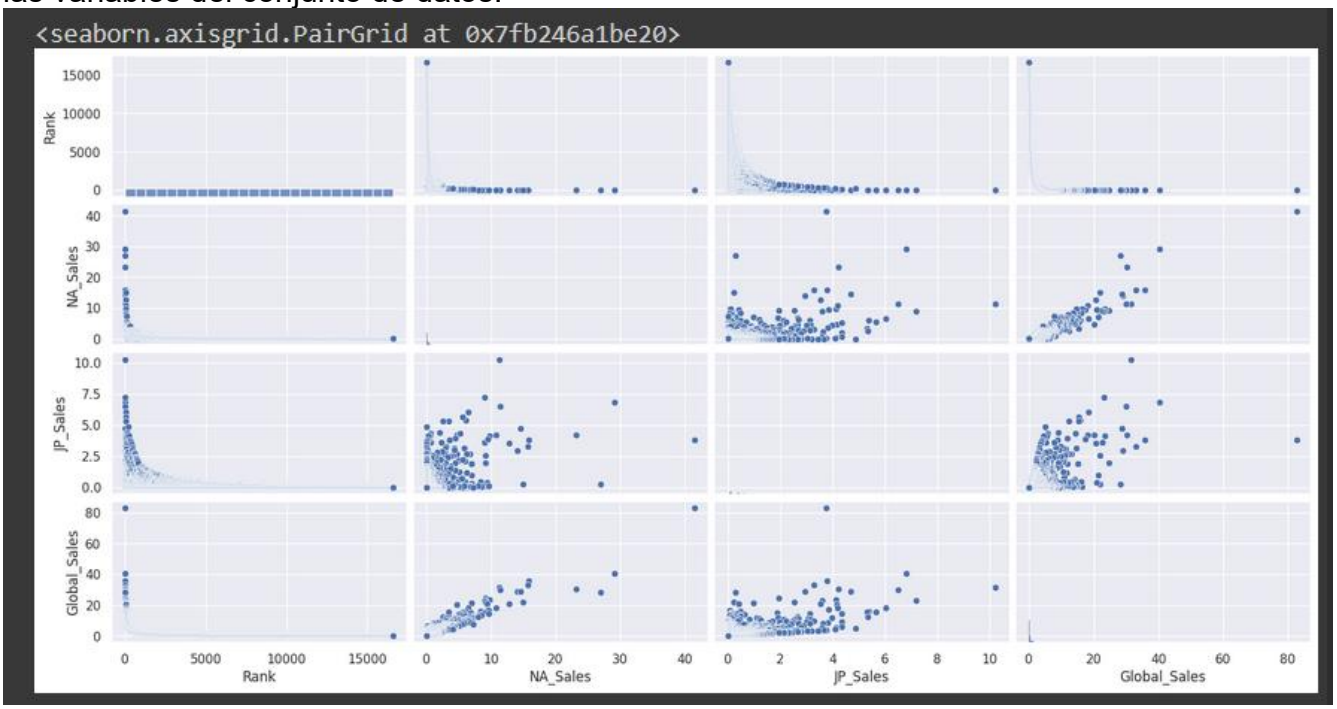

Los análisis aquí se hacen evidentes y además es el comportamiento natural, dado que en todos los casos el ranking de un juego es directamente proporcional al número de copias vendidas. También es evidente que el número de copias vendidas a nivel global es directamente proporcional al número de copias vendidas a nivel de regiones y/o países. Hay una pequeña excepción con Japón, en el cual se puede notar una mayor cantidad de copias vendidas respecto a otras regiones y a nivel global.

Debido a la naturaleza de los datos de las columnas "Year" y "Publisher" se ha decido borrar las filas que no poseen estos datos ya que no es posible reemplazarlos por valores calculados. A continuación, se puede observar la cantidad de entradas que quedaron respecto a las que habían antes de la limpieza.

```
### Limpieza de datos, solución a datos faltantes ###
#df.Year.fillna(df.Year.mean(), inplace=True)
dfn = df.dropna()
#dn = dn[[i for i in dn.columns if df[i].dtype!=object]]
print ("Dimensiones de dataframe original: ", df.shape)
print ("Dimensiones de dataframe nuevo: ",  dfn.shape)
#dlr = dn.copy()
#aux = df["Year"].copy()
#aux[aux.isna()] = np.random.normal(loc=np.mean(aux), sca
#dlr["Year"] = aux
#dlr
dfn
```

```
Dimensiones de dataframe original:  (16598, 10)
Dimensiones de dataframe nuevo:  (16291, 10)
```

Seguidamente se verifica que ya no existan datos faltantes dentro del dataset.

```
Rank            0
Platform        0
Year            0
Genre           0
Publisher       0
NA_Sales        0
EU_Sales        0
JP_Sales        0
Other_Sales     0
Global_Sales    0
dtype: int64
```

El siguiente paso es convertir el tipo de dato de año en un entero ya que se encuentra en un formato de Float.

```
1 ### Conversión a tipo de dato entero de la columna "Year" y verificación ###
2 dfn['Year'] = dfn['Year'].astype(np.int64)
3 print(dfn.dtypes)
4 print(dfn['Year'].unique())
5 len(dfn['Year'].unique())
```

```
Rank             int64
Platform        object
Year             int64
Genre           object
Publisher       object
NA_Sales       float64
EU_Sales       float64
JP_Sales       float64
Other_Sales    float64
Global_Sales   float64
dtype: object
```

Ya con el dataset preparado se procede a generar un conjunto de datos con las variables dependientes y la variable independiente o de salida.

```
1 ### Separación de las variables dependientes y la variable independiente ###
2 x = dfn.drop(['Genre'], axis=1)
3 y = dfn['Genre'].values
4 print(x.head(5), type(x), '\n')
5 print(y, type(y))
```

```
                        Rank Platform  Year Publisher  NA_Sales  EU_Sales  \
Name
Wii Sports                 1      Wii  2006  Nintendo     41.49     29.02
Super Mario Bros.          2      NES  1985  Nintendo     29.08      3.58
Mario Kart Wii             3      Wii  2008  Nintendo     15.85     12.88
Wii Sports Resort          4      Wii  2009  Nintendo     15.75     11.01
Pokemon Red/Pokemon Blue   5       GB  1996  Nintendo     11.27      8.89

                        JP_Sales  Other_Sales  Global_Sales
Name
Wii Sports                  3.77         8.46         82.74
Super Mario Bros.           6.81         0.77         40.24
Mario Kart Wii              3.79         3.31         35.82
Wii Sports Resort           3.28         2.96         33.00
Pokemon Red/Pokemon Blue   10.22         1.00         31.37   <class 'pandas.core.frame

['Sports' 'Platform' 'Racing' ... 'Racing' 'Puzzle' 'Platform'] <class 'numpy.ndarray'>
```

El siguiente paso ha sido el de codificar las variables categóricas. Es de resaltar que en este punto, no se debe olvidar que al etiquetar las variables categóricas con números, los algoritmos podrían dar un peso numérico, lo cual puede acarrear lecturas incorrectas.

```
### Tratamiento de las variables categóricas ###
from sklearn.preprocessing import LabelEncoder, OneHotEncoder
from sklearn.compose import ColumnTransformer
label_encoder_y = LabelEncoder()
label_encoder_x = LabelEncoder()
y[:][:] = label_encoder_y.fit_transform(y)
x.iloc[:, 1] = label_encoder_x.fit_transform(x.values[:, 1])
x.iloc[:, 3] = label_encoder_x.fit_transform(x.values[:, 3])
#ct = ColumnTransformer([("Publisher", OneHotEncoder(), [3])],
#x = ct.fit_transform(x)
print(type(y))
print(y.dtype)
#for i,x in enumerate(y_pred):
#    y_pred[i]=x.astype('int')
print(y, '\n')
y=y.astype('int')
print(type(y))
print(y.dtype)
print(np.unique(y))
```

```
<class 'numpy.ndarray'>
object
[10 4 6 ... 6 5 4]

<class 'numpy.ndarray'>
int64
```

Se procede a asignar los datos que serán para entrenamiento y los que serán para prueba del conjunto de datos

```
### Selección de los datos de entrenamiento y los datos de prueba ###
from sklearn.model_selection import train_test_split, KFold
(x_train, x_test, y_train, y_test) = train_test_split(x, y)
print("Tamaño de dataset de variables dependientes: ", x.shape)
print("Tamaño de vector de variable independiente: ", y.shape)
print("Tamaño de datos de entrenamiento: ", x_train.shape)
print("Tamaño de datos de prueba: ", x_test.shape, '\n')
print("Salida de entrenamiento: ", y_train.shape)
print("Salida de prueba: ", y_test.shape)
```

```
Tamaño de dataset de variables dependientes:  (16291, 9)
Tamaño de vector de variable independiente:  (16291,)
Tamaño de datos de entrenamiento:  (12218, 9)
Tamaño de datos de prueba:  (4073, 9)

Salida de entrenamiento:  (12218,)
Salida de prueba:  (4073,)
```

Para los datos de entrenamiento se emplearán 12218 entradas del total de 16291.
Las entradas restantes (4073), serán empleados como datos de test o prueba.

Los modelos con los que se trabajó fueron arboles de decisión de clasificación y regresión logística. Se intentó ejecutar un modelo de máquinas de soporte vectorial, pero esta presentó problemas al momento de realizar los ajustes por lo cual se descartó.

```
### Selección de los modelos a emplear###
from sklearn import model_selection
from sklearn.preprocessing import PolynomialFeatures, StandardScaler
import matplotlib.pyplot as plt
from sklearn.tree import DecisionTreeClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.svm import SVC
p_score = lambda model, score: print('Performance of the %s model is %0.2f%%' % (model, score * 100))
sc = StandardScaler()
x_train_decitree = sc.fit_transform(x_train) #Ajuste de escalas
x_test_decitree = sc.transform(x_test)#Ajuste de escalas
y_train_decitree = y_train
### Decision Tree Classifier
classifier = DecisionTreeClassifier(criterion = 'entropy', random_state = 0)
classifier.fit(x_train_decitree, y_train_decitree)
```

Se realiza el ajuste y la predicción con el árbol de decisión y se visualiza una matriz de confusión como métrica. Los resultados se pueden observar a continuación.

```
# Predicción
y_pred = classifier.predict(x_test_decitree)
# Matriz de confusión
from sklearn.metrics import confusion_matrix, ConfusionMatrixDisplay
import matplotlib.pyplot as plt
cm = confusion_matrix(y_test, y_pred)
print(cm.shape)
disp = ConfusionMatrixDisplay(confusion_matrix=cm)
disp.plot()
```

```
(12, 12)
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at 0x7f9c2e2ae470>
```

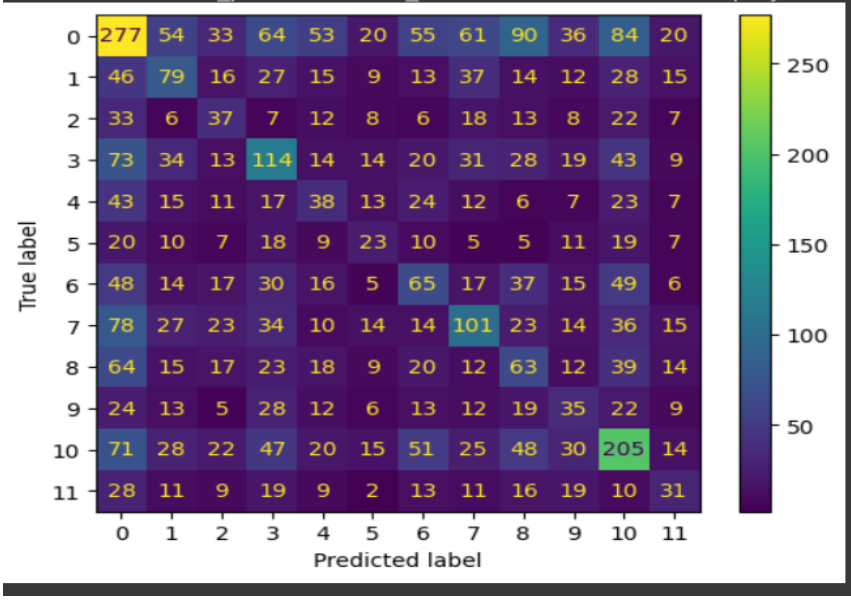

Después hacer el análisis, se concluye que la cantidad de aciertos es baja en este modelo, siendo un total de aciertos de 1068 elementos del total de 4073 del conjunto de datos de salida. Por lo tanto, se observa que tan solo el 26.22% de los datos han sido verdaderos positivos, así que se puede decir que es un porcentaje bastante bajo de acierto. Se puede observar en la matriz que los géneros que mayor cantidad de aciertos tuvieron fueron "Action" y "Sports". El género y su codificación se puede observar a continuación.

```
### No se logró decodificar el arreglo de salida por lo que se hizo
### un diccionario para relacionar los géneros de videojuegos ###
y_n=label_encoder_y.inverse_transform(np.unique(y))
genero = {
    "0": "Action",
    "1": "Adventure",
    "2": "Fighting",
    "3": "Misc",
    "4": "Platform",
    "5": "Puzzle",
    "6": "Racing",
    "7": "Role-Playing",
    "8": "Shooter",
    "9": "Simulation",
    "10": "Sports",
    "11": "Strategy"
}
print(cm.shape)
print(type(cm))
diag=cm.sum()
print(diag)
true_positive = np.trace(cm)
print(true_positive)
porcentaje = (true_positive*100)/diag
print(porcentaje)
```

```
(12, 12)
<class 'numpy.ndarray'>
4073
1068
26.22145838448318
```

Para el modelo de regresión logística, se realiza el ajuste del modelo con los datos de entrenamiento al igual que con el modelo anterior y se realiza una validación cruzada K-fold. Estos son los resultados a continuación.

```
### Regresión logística ###
from sklearn.model_selection import cross_val_score
from sklearn.metrics import accuracy_score
x_train_lr = sc.fit_transform(x_train) #Ajuste de escalas
x_test_lr = sc.transform(x_test)#Ajuste de escalas
y_train_lr = y_train
### Clasificadores ###
model1 = LogisticRegression()
#model1 = SVC(kernel="linear", C=0.025)
#model2 = SVC(gamma=2, C=1)
#scores = cross_val_score(model1, x_train, y_train, cv=3)
model1.fit(x_train_lr, y_train_lr)
name='Logistic Regression'
kfold = KFold(n_splits=10, random_state=None)
cv_results = model_selection.cross_val_score(model1, x_train_lr, y_train_lr, cv=kfold, scoring='accuracy')
score = "%s: %f (%f)" % (name, cv_results.mean(), cv_results.std())
print(score)
y_pred_rl = model1.predict(x_test_lr)
print(accuracy_score(y_test, y_pred_rl))
```

```
Logistic Regression: 0.224095 (0.012199)
0.22759636631475572
/usr/local/lib/python3.10/dist-packages/sklearn/linear_model/_logistic.py:458: ConvergenceWarning:
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
```

Como se puede observar, los resultados de los puntajes tanto de la media y la desviación estándar de la validación cruzada y de la precisión del modelo, no son muy buenos siendo estos de 0.224, 0.012 y 0.227 respectivamente.

Como conclusión se puede decir que se requiere el uso de otros diferentes modelos y de mas pruebas de ensayo y error con diversos parámetros de los modelos usados y otros modelos a implementar.